

**École Nationale de la Statistique
et de l'Analyse Économique**

Dakar, Sénégal

Traitement de données

**Enquête Régionale Intégrée sur l'Emploi
et le Secteur Informel (ERI-ESI 2017)**

Rapport de synthèse – Groupe 1

Membres du groupe : Ndeye Aïssatou CISSE

Papa Maguette DIOP

Aïssatou GUEYE

Awa GUEYE

Marc MARE

Qualité : Analystes statisticiens en fin de formation

Dépôt GitHub : `papamagattediop/Traitements_de_donnees-ERI-ESI-`

Année académique 2024-2025

1. Contexte et objectifs

L'ERI-ESI (Enquête Régionale Intégrée sur l'Emploi et le Secteur Informel) est une opération statistique conjointe conduite en 2017 par l'ANSD, l'AFRISTAT et l'UEMOA dans plusieurs pays membres. Le volet sénégalais, objet de ce travail, porte sur l'emploi, les conditions d'activité et le secteur informel.

L'objectif du projet est de construire un pipeline de traitement reproductible à partir des fichiers bruts de l'enquête, en produisant deux tables analytiques consolidées (individus et ménages) ainsi qu'un ensemble de contrôles de qualité et d'estimations de référence. Le pipeline est conçu pour être généralisable aux autres volets pays de l'ERI-ESI, moyennant l'adaptation d'un bloc de configuration centralisé.

2. Sources de données

Deux fichiers `.dta` constituent les entrées du pipeline.

Fichier	Contenu	Obs.	Variables
<code>individus_TP.dta</code>	Roster des membres du ménage	120 693	53
<code>emploi_Tp.dta</code>	Module emploi individuel	120 689	492

TABLE 1 – Fichiers sources (volet Sénégal, ERI-ESI 2017)

Les deux fichiers sont appariés sur la clé `hh1 + hh2 + m1` (grappe, ménage, numéro d'ordre de l'individu). Quatre individus du roster n'ont pas de correspondance dans le module emploi, ce qui est cohérent avec le champ d'application de ce module, restreint aux personnes de dix ans et plus. La base fusionnée regroupe ainsi 120 693 lignes et 543 variables.

Les fichiers de données, trop volumineux pour être versionnés (807 Mo, 82 Mo et 99 Mo respectivement), sont mis à disposition par voie externe, conformément aux instructions précisées dans le fichier `README.md` du dépôt.

3. Pipeline de traitement

Le pipeline est entièrement implémenté en Stata 18. Il s'articule en six scripts exécutés séquentiellement depuis la racine du dépôt.

La configuration pays (chemins, noms de fichiers, clés de fusion) est centralisée dans `config.do`. L'adaptation à un autre pays de l'UEMOA ne requiert que la modification de ce bloc, sans toucher à la logique de traitement.

Script	Entrée	Sortie
01_fusion.do	individus_TP.dta, emploi_Tp.dta	base_individus_emploi_fus
03_demographie_geo.do	Base fusionnée	individus_demo_geo.dta
03_emploi_principal.do	Base fusionnée	emploi_principal.dta
04_emploi_secondaire.do	Base fusionnée	emploi_secondaire.dta
05_menages.do	individus_demo_geo.dta	menages.dta
06_consolidation.do	Sorties des modules 03 à 05	individus_consolide.dta, menages_consolide.dta

TABLE 2 – Séquence d'exécution du pipeline

4. Variables construites

4.1 Module démographie et géographie

Ce module construit les variables individuelles de base à partir du roster : sexe, âge et groupe d'âge (huit tranches), lien de parenté avec le chef de ménage (détaillé et regroupé en cinq postes), situation matrimoniale, niveau d'études consolidé (six niveaux) et branche d'études. La région et le milieu de résidence (urbain/rural) sont également retenus. Cinq indicateurs de contrôle (flags) signalent les incohérences détectées sans modifier les observations.

4.2 Module emploi principal

La situation d'activité est issue de la variable synthétique `sitac` produite par l'ANSD, regroupée en quatre postes : actif occupé, chômeur BIT, main-d'oeuvre potentielle et inactif. Pour les actifs occupés, le module construit le statut dans l'emploi, le type (sala-rié/indépendant), le secteur d'activité selon la nomenclature ISIC Rév. 4 (21 sections et regroupement en quatre familles), les heures travaillées par semaine, le sous-emploi lié à la durée, le revenu mensuel consolidé et les indicateurs de formalité de l'unité de production et de l'emploi.

Cinq correspondances erronées ont été identifiées lors de la vérification du dictionnaire initial par croisement avec le questionnaire et les métadonnées du fichier. Les corrections apportées figurent dans le tableau ci-dessous.

4.3 Module emploi secondaire

Le module traite le premier emploi secondaire déclaré (suffixe `_AS1`), seul statistique-ment significatif (118 répondants seulement pour le second). Il construit le statut, le type d'emploi, le secteur d'activité, les heures hebdomadaires (converties depuis des minutes par jour renseignées dans `AS9C`), le revenu mensuel et la formalité de l'emploi. Une variable

Variable	Initiale	Corrigée	Note
Situation matrimoniale	M5	M25	M5 est le lieu de naissance
Secteur ISIC principal	AP4	AP2_Niv1	AP4 est le secteur institutionnel
Heures travaillées	AP6A	AP10C	AP6A est le régime fiscal
Revenu principal	AP8A1	AP13A/B/C	AP8A1 est l'ancienneté dans l'emploi
Raison d'inactivité	SE9	SE11	SE9 est la disponibilité à travailler

TABLE 3 – Corrections apportées au dictionnaire de variables

indicatrice signale les codes sectoriels potentiellement issus d'une révision antérieure de la nomenclature ISIC.

4.4 Table ménages

La table ménages est construite à partir du chef de ménage identifié dans le roster. Elle contient les caractéristiques démographiques et géographiques du chef, la structure du ménage (taille, répartition par sexe, nombre de membres de moins de 15 ans et de 15 ans et plus) ainsi que, après consolidation, les agrégats d'emploi au niveau ménage (nombre d'actifs occupés, de salariés, d'emplois informels et ratio de dépendance).

5. Contrôle qualité

Chaque module produit deux fichiers de sortie complémentaires : un fichier de contrôles de cohérence (qc_*.csv) listant les anomalies détectées avec leur effectif, et un fichier d'estimations pondérées (estimations_*.csv) permettant la comparaison avec les chiffres publiés par l'ANSD. Le module de consolidation produit également des contrôles croisés portant sur la cohérence entre les tables individus et ménages.

Les estimations clés obtenues sur le volet emploi, comparées aux valeurs de référence du rapport final ANSD (2017), sont présentées ci-dessous à titre indicatif.

Indicateur	Pipeline	ANSD
Taux de chômage BIT (%)	recalculé	2,9
Taux de salarisation (%)	recalculé	38,6
Part des indépendants parmi les occupés (%)	recalculé	66,1
Taux d'emploi informel (%)	recalculé	95,4
Secteur primaire parmi les occupés (%)	recalculé	24,7
Secteur commerce parmi les occupés (%)	recalculé	27,6

TABLE 4 – Indicateurs d'emploi – valeurs de référence ANSD (2017)

La colonne « Pipeline » est à renseigner après exécution complète sur les données réelles, les fichiers bruts n'étant pas versionnés dans le dépôt.

6. Reproductibilité et généralisation

L'ensemble du pipeline est reproductible depuis la racine du dépôt en exécutant les six scripts dans l'ordre indiqué au tableau 2. La seule condition préalable est la présence des fichiers sources dans le répertoire `input/SEN/`. L'adaptation à un autre pays de l'UEMOA ne nécessite que la modification du bloc global dans `config.do` (code pays, noms de fichiers, clés de fusion et noms de variables si la nomenclature du questionnaire diffère).

Le dépôt est organisé comme suit : `scripts/stata/` pour les scripts de traitement, `docs/` pour la documentation et le présent rapport, `input/` et `output/` pour les données (non versionnées). Un fichier `README.md` décrit l'organisation du projet et les étapes d'exécution.

7. Conclusion

Ce travail produit un pipeline de traitement structuré et documenté pour les données ERI-ESI 2017, volet Sénégal. Les deux tables analytiques finales (individus et ménages) couvrent l'ensemble des dimensions thématiques accessibles dans les fichiers du volet emploi : démographie, géographie, situation d'activité, emploi principal et secondaire, formalité et revenus. La démarche de contrôle qualité intégrée à chaque module garantit la traçabilité des choix méthodologiques et facilite la comparaison avec les statistiques officielles publiées par l'ANSD.